

multi-head head attention

Основной недостаток Self-Attention - **работа в едином пространстве признаков**, что заставляет один механизм одновременно решать все типы задач (синтаксис, семантика, анафора, локальный контекст). Это снижает способность выделять разные виды зависимостей.

Multi-Head Attention решает это путём параллельного выполнения нескольких независимых операций внимания в разных подпространствах, позволяя каждой "голове" специализироваться на своём аспекте данных.

вместо одного механизма внимания, работающего в едином пространстве (схема $X \rightarrow QKV \rightarrow Attention \rightarrow Output$), предлагается **Multi-Head Attention**.

Реализация: входной вектор X параллельно подаётся на несколько независимых "голов" (*Head 1, 2, 3, 4...*), каждая из которых выполняет свой собственный Self-Attention.

Результат: каждая голова учится фокусироваться на разных типах зависимостей (например, одна - на синтаксисе, другая - на семантике, третья - на позиционной близости), а их выходы затем объединяются. Это решает проблему "одного механизма на всё сразу".

В обычном scaled self-attention одна тройка матриц для всех вычислений, а в multi-head attention у каждой головы своя собственная тройка (W_{Q1}, W_{K1}, W_{V1} для первой головы, W_{Q2}, W_{K2}, W_{V2} для второй, W_{Qn}, W_{Kn}, W_{Vn} для n -ной головы).

Multi в Multi-Head Attention возникает именно на этапе **объединения** результатов.

1. Каждая голова выдаёт свою матрицу (например, размерности 4×2).
2. Все выходы **конкатенируются** по последней размерности: $4 \times (2 * \text{кол-во голов})$

После конкатенации есть ещё одна обучаемая матрица $W_O \in \mathbb{R}^{d_{\text{model}} \times d_{\text{model}}}$, которая смешивает информацию всех голов, это надо чтобы вернуться к исходной размерности. Поэтому,

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O$$

где

$$\text{head}_i = \text{Attention}(Q_i, K_i, V_i)$$

Размерности

Предположим что

```
d_model = 512  
heads = 8
```

Тогда, каждая голова работает с $d_k = \frac{512}{8} = 64$ измерениями.

```
Embeddings  
(T, d_model)  
  |  
  ▼  
Q, K, V  
(T, d_k)
```

